

# Gemi Tespit ve Uyarı Sistemi

## Proje Özeti

Gemi tespiti, özellikle güvenlik, lojistik ve çevre koruma gibi kritik alanlarda büyük bir öneme sahiptir. Uluslararası sularda veya ülkelerin kara sularında seyreden gemilerin izlenmesi, olası kaçakçılık, terörizm ve diğer suç faaliyetlerinin önlenmesi açısından son derece önemlidir. Ayrıca, savaş gemilerinin veya şüpheli gemilerin tespiti, bir ülkenin güvenliğini sağlamak için stratejik bir rol oynar. Bu bağlamda, gemi tespit sistemlerinin geliştirilmesi, deniz güvenliği ve ulusal savunma için kritik bir araçtır.

Bu projede, kullanıcılar mobil uygulama üzerinden bir gemi görüntüsü yükleyerek gemi sınıflandırması yapılması sağlanmıştır. Yapay zeka destekli model, yüklenen görüntüyü analiz ederek gemiyi tanımlayarak tehlikeli olup olmadığını belirlemektedir. Eğer sistem, yüklenen gemiyi "savaş gemisi" olarak sınıflandırırsa, sistem anında yetkililere bir bildirim göndermektedir. Ayrıca, geminin tespit edilen konumu harita üzerinde işaretlenip bu veriler veri tabanına kaydedilmektedir. Oluşturulan modelin eğitim doğruluk oranı %90, doğrulama doğruluk oranı %89 ve test doğruluk oranı %91'dir.

## 1.Giriş

Deniz yollarındaki yoğunluk, güvenlik tehditleri ve yasa dışı faaliyetler, gemi tespiti ve takibini günümüzde hayati bir ihtiyaç hâline getirmiştir. Özellikle savaş gemileri ya da şüpheli deniz taşıtlarının zamanında fark edilmesi, ülkelerin güvenliğini sağlamak ve olası tehlikelere karşı önlem almak açısından büyük önem taşımaktadır.

Mevcut gözetim sistemleri genellikle sabit merkezlere kuruludur ve gerçek zamanlı uyarı mekanizmaları ya da yapay zeka destekli sınıflandırma özelliklerinden yoksundur. Ayrıca, bireysel kullanıcıların mobil cihazlar aracılığıyla gözlem yapabilmesi çoğu sistemde mümkün değildir.

Bu bağlamda, hem mobil cihazlarla kullanılabilen hem de yapay zeka destekli otomatik gemi tanıma ve uyarı mekanizmasına sahip bir sistem ihtiyacı ortaya çıkmaktadır. Gemi görüntüsünün analiz edilerek sınıflandırılması, tehlikeli durumlarda yetkililere anlık bildirim gönderilmesi ve geminin bulunduğu konumun harita üzerinde işaretlenip veri tabanına kaydedilmesi, çözüm bekleyen temel problemlerdir.

## 2.Literatür Taraması

Gemi tespiti ve sınıflandırması, son yıllarda bilgisayarla görme ve derin öğrenme alanlarındaki gelişmeler sayesinde daha etkili ve otonom sistemlerle gerçekleştirilebilmektedir. Özellikle Convolutional Neural Network (CNN) tabanlı yaklaşımlar, gemilerin türünü yüksek doğrulukla tanıyabilen yapay zeka modellerinin geliştirilmesini mümkün kılmıştır.

Tiwari, Munagala ve Mannarugudi (2024), CNN mimarileriyle transfer öğrenme yaklaşımını birleştirerek gemi sınıflandırma için yüksek doğruluk oranlarına ulaşmış, bu yöntemin akıllı gemi

yönlendirme sistemleri için etkili bir temel sunduğunu belirtmiştir [1]. Modelin farklı CNN tabanlı mimarilerle test edilmesi, transfer öğrenmenin bu alandaki başarıyı nasıl artırdığını göstermektedir.

Stofa, Zulkifley ve Zaki (2020), uydu görüntüleri üzerinde gerçekleştirdikleri çalışmada, derin öğrenmenin özellikle düşük çözünürlüklü veya karmaşık çevresel koşullarda bile gemi tespitinde etkin olduğunu göstermiştir [2]. Bu çalışmada farklı CNN modelleriyle yapılan deneylerde, deniz ortamının doğası gereği oluşan gürültüye rağmen oldukça başarılı sonuçlar elde edilmiştir.

Zhang ve arkadaşları (2018), SAR (Sentetik Açıklıklı Radar) görüntüleri üzerinde transfer öğrenme kullanarak gerçekleştirdikleri gemi tanıma çalışmasında, önceden eğitilmiş CNN modellerinin SAR gibi farklı veri tiplerinde bile güçlü sonuçlar verdiğini ortaya koymuştur [3]. Bu tür görüntüler, özellikle gece veya bulutlu havalarda klasik optik görüntüleme sistemlerine göre daha avantajlıdır.

Veri seti açısından bakıldığında, Xia ve arkadaşlarının (2018) sunduğu DOTA veri seti, hava görüntülerinde gemi gibi küçük nesneleri tanımaya yönelik geliştirilmiş, büyük ölçekli ve çeşitlendirilmiş bir veri seti sunmaktadır [4]. DOTA, bu tür çalışmalarda geniş sınıf yelpazesi ve farklı ölçeklerde nesne içerdiği için modelin genelleme kapasitesini test etmek açısından oldukça değerlidir.

Tüm bu çalışmaların temelinde yer alan derin öğrenme modellerinin geliştirilmesi sürecinde, TensorFlow gibi büyük ölçekli açık kaynaklı yazılım kütüphaneleri önemli rol oynamaktadır. Abadi ve arkadaşlarının (2016) geliştirdiği TensorFlow platformu, bu tür projelerde model eğitimi, değerlendirme ve dağıtım işlemlerinin optimize edilmesini sağlamaktadır [5].

Sonuç olarak, literatürde gemi tespiti için önerilen yöntemlerin çoğu, CNN tabanlı derin öğrenme yaklaşımlarının farklı görüntü kaynaklarıyla ve veri setleriyle desteklenmesiyle yüksek doğruluk oranlarına ulaşmaktadır. Ancak mobil cihazlarla kullanılabilen, anlık konum takibi ve uyarı sistemleriyle bütünleşmiş yapılar hâlâ sınırlıdır. Bu proje, bu boşluğu kapatmaya yönelik bütünleşik bir sistem önererek literatüre katkı sağlamaktadır.

### **3.Yöntem**

Bu projede, gemi türlerini sınıflandırmak ve savaş gemileri tespit ederek uyarı sistemi oluşturmak amacıyla yapay zeka, mobil yazılım geliştirme, bildirim sistemi ve google maps bir arada kullanılmıştır. Sistem, dört temel bileşenden oluşmaktadır: veri hazırlama, model eğitimi, backend geliştirme ve mobil arayüz entegrasyonu.

#### **Veri Hazırlama**

Veri hazırlama süreci, modelin başarısı için kritik bir aşamadır. Çeşitli gemi türlerine ait görseller internetten manuel olarak toplanmış ve sınıflandırılmıştır. Toplamda 4000 görüntüden oluşan veri seti, Cruise\_ship, Warship, Freight\_boat, Ferry\_boat ve Sail\_boat olmak üzere 5 sınıfa bölünmüştür. Her sınıfta 800 görüntü bulunacak şekilde dengelenmiştir.

Veri seti, %64 eğitim, %16 doğrulama ve %20 test olacak şekilde ayrılmıştır. Görseller, 128x128 piksele yeniden boyutlandırılmış ve piksel değerleri [0,1] aralığına normalize edilmiştir. Veri artırma (augmentation) yöntemleri olarak döndürme (rotation), yakınlaştırma (zoom), yatay/ters çevirme

(flip) ve parlaklık deęişiklikleri gibi yöntemler uygulanmıştır. Bu yöntemler, modelin aşırı öğrenmesini önlemeye ve genelleme kapasitesini artırmaya yönelik seçilmiştir.

### Derin Öğrenme Modeli Eğitimi

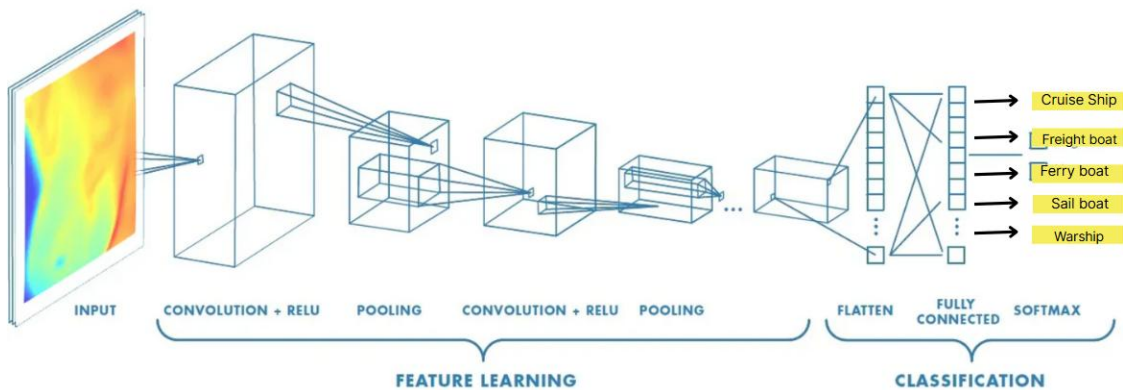
Bu projede, gemi türlerini sınıflandırmak amacıyla sıfırdan bir Convolutional Neural Network (CNN) mimarisi tasarlanmış ve TensorFlow/Keras kütüphaneleri kullanılarak eğitilmiştir. Modelin giriş katmanı, her biri 128x128 piksel boyutunda ve üç renk kanalına (RGB) sahip olan görüntüleri alacak şekilde yapılandırılmıştır.

Model mimarisi, dört adet konvolüsyon (Conv2D) katmanı ve her birinin ardından gelen maksimum havuzlama (MaxPooling2D) katmanlarından oluşmaktadır. İlk konvolüsyon katmanında 32 filtre, ikinci katmanda 64 filtre, üçüncü ve dördüncü katmanlarda ise 128'er filtre kullanılmıştır. Her konvolüsyon katmanında ReLU (Rectified Linear Unit) aktivasyon fonksiyonu uygulanarak doğrusal olmayanlık eklenmiş ve modelin karmaşık desenleri öğrenebilmesi sağlanmıştır. MaxPooling katmanları ise görsel bilgiyi sıkıştırarak modelin gereksiz detayları atmasına ve daha yüksek düzeydeki özellikleri öğrenmesine yardımcı olmuştur.

Konvolüsyon ve havuzlama katmanlarının ardından, elde edilen çok boyutlu özellik haritaları (feature maps) Flatten katmanı ile düzleştirilmiş ve bir adet 256 nöronlu tam bağlantılı (Dense) katmana iletilmiştir. Bu katmanda da ReLU aktivasyonu kullanılmıştır. Son katmanda ise, sınıf sayısı kadar nöron bulunan bir Dense katman yer almakta ve softmax aktivasyon fonksiyonu aracılığıyla her sınıfa ait olasılık deęerleri hesaplanmaktadır.

Model, adam optimizasyon algoritması ve categorical crossentropy kayıp fonksiyonu kullanılarak derlenmiştir. Eğitim sürecinde, eğitim ve doğrulama performansını izlemek için ModelCheckpoint callback'i eklenmiş ve doğrulama doğruluęu (val\_accuracy) en yüksek olan model ağırlıkları .h5 formatında kaydedilmiştir. Model toplamda 50 epoch boyunca eğitilmiş, her epoch sonunda doğrulama verisi üzerinden modelin başarıımı deęerlendirilmiştir.

Bu yapı, gemi türlerinin görüntülerden doğru bir şekilde sınıflandırılması için hem düşük hem de yüksek seviyeli özellikleri öğrenebilen, güçlü ve optimize edilmiş bir derin öğrenme mimarisi sunmaktadır.



3.1 CNN mimarisi görseli: Sonuç olarak 5 sınıftan birine sınıflandırma yapmaktadır.

## Backend Geliştirme (FastAPI)

Backend geliştirme sürecinde FastAPI framework'ü tercih edilmiştir. Backend sunucusu, kullanıcıdan gelen gemi görüntüsünü alarak TensorFlow modeli ile sınıflandırmakta ve geminin türünü belirlemektedir. Eğer sınıflandırma sonucunda gemi "savaş gemisi" olarak tespit edilirse, sistem Firebase Cloud Messaging (FCM) aracılığıyla yetkililere anında bildirim göndermektedir. Ayrıca, kullanıcının konumu Google Maps API ile alınarak sınıflandırma sonucu ile birlikte Firebase Firestore veri tabanına kaydedilmektedir. Böylece yalnızca sınıflandırma değil, gerçek zamanlı konum takibi ve olay kaydı da sağlanmıştır.

## Mobil Uygulama (Flutter)

Kullanıcı arayüzü, Flutter kullanılarak geliştirilen bir mobil uygulama ile sağlanmıştır. Bu uygulama, kullanıcıların cihazlarındaki kamera veya galeriden görüntü ya da video seçmesine olanak tanır. Uygulama, kullanıcının anlık konumunu alarak seçilen görüntüyle birlikte backend sunucusuna iletir. Sunucudan gelen sınıflandırma sonucu kullanıcıya gösterilmekte; eğer sistem tarafından bir tehdit algılanırsa, ilgili birime otomatik olarak bildirim gönderilmektedir. Bu yapı sayesinde kullanıcılar basit bir mobil arayüz üzerinden etkin ve güvenli bir gemi tespiti gerçekleştirebilmektedir.

### 3.1 Veri Seti ve Özellikleri

Bu projede kullanılan veri seti, tarafımdan internet üzerinden manuel olarak toplanmış ve sınıflandırılmıştır. Veri seti, gemi türlerini tanıyabilen bir yapay zeka modelinin eğitilmesine uygun olacak şekilde düzenlenmiş ve dengeli bir yapı oluşturulmuştur.

Veri seti toplamda 5 farklı gemi sınıfı içermektedir. Her bir sınıf, farklı görsel özellikler taşıyan 800 adet gemi fotoğrafından oluşmaktadır. Böylece toplamda 4000 etiketli gemi görüntüsü kullanılmıştır. Görüntüler açık deniz, liman veya çeşitli perspektiflerde olacak şekilde çeşitlendirilmiş ve modelin genelleme gücünü artırmaya yönelik olarak seçilmiştir.

Kullanılan Sınıflar:

- Cruise\_ship: Büyük yolcu gemileri. Çok katlı yapıları ve beyaz gövdeleriyle dikkat çeker.
- Warship: Savaş gemileri. Genellikle gri renkli, düz yapılı ve radar/silah sistemleri içerir.
- Freight\_boat: Yük taşımacılığı yapan konteyner gemileri. Uzun ve geniş yapılıdır.
- Ferry\_boat: Şehir içi veya kıyı taşımacılığı yapan feribotlar. Düz tabanlı, yolcu ve araç kapasiteli teknelerdir.
- Sail\_boat: Yelkenli küçük tekneler. Rüzgarla hareket eden ve sivri yapılı gövdelere sahiptir.

Veri seti %64 eğitim, %16 doğrulama ve %20 test olmak üzere üç gruba ayrılmıştır. Bu sayede modelin eğitimi sırasında öğrenme, doğrulama ve test aşamaları ayrı olarak değerlendirilmiştir.

#### 4. Oluşturulan model ve bulgular

Eğitilen CNN modelinin performans değerleri aşağıda verilmektedir:

- Eğitim Doğruluğu: %90.17
- Doğrulama Doğruluğu: %89.91
- Test Doğruluğu: %91.78
- Eğitim Kayıp (Loss): 0.3152
- Doğrulama Kayıp: 0.3158
- Test Kayıp: 0.2951

Bu sonuçlar, modelin hem eğitim hem de yeni veriler üzerinde genelleme başarısının oldukça iyi olduğunu göstermektedir. Aşırı öğrenme (overfitting) gözlenmemiştir.

##### Test verisi için sınıflandırma raporu özeti:

Sınıf	Precision	Recall	F1-Score	Support
cruise_ship	0.91	0.92	0.92	163
ferry_boat	0.89	0.87	0.88	161
freight_boat	0.93	0.90	0.91	162
sailboat	0.93	0.97	0.95	166
warship	0.92	0.93	0.93	163


##### Genel Ölçüm Precision Recall F1-Score Support

accuracy			0.92	815
macro avg	0.92	0.92	0.92	815
weighted avg	0.92	0.92	0.92	815

Sailboat (yelkenli) sınıfında F1-score %95 ile en yüksek başarıya ulaşılmıştır. Bu, modelin yelkenli gemileri ayırt etmekte çok başarılı olduğunu gösteriyor. Warship (savaş gemisi) sınıfında da %93 F1-score elde edilmiş, ki bu güvenlik uygulamaları açısından çok önemli çünkü yanlış alarm ya da eksik tespit riski düşük olduğunu göstermektedir. Ferry\_boat (feribot) sınıfında F1-score %88 ile biraz daha düşük. Bu, modelin feribotları ayırt ederken zaman zaman başka sınıflarla karıştırabildiğini veya bazı feribot örneklerini yanlış sınıflandırdığını düşündürmektedir.

Macro average (sınıf başına ortalama) ve weighted average (veri sayısına göre ağırlıklı ortalama) değerleri precision, recall ve F1-score için hepsinde %92 çıkmış. Bu, sınıflar arasında genel başarının dengeli olduğunu, hiçbir sınıfın ihmal edilmediğini veya çok baskın olmadığını gösteriyor.

#### Karmaşıklık matrisi (Confussion matrix)



4.1 Modelin karmaşıklık matrisi verilmiştir.

#### Geliştirilebilecek noktalar

Her ne kadar model genel olarak yüksek performans sergilese de, bazı eksik ve geliştirilmesi gereken yönler dikkat çekmektedir. Öncelikle, ferry\_boat sınıfındaki görece düşük F1 skoru (%88), bu sınıfın görsel olarak diğer sınıflarla karıştırılabildiğini göstermektedir. Bu durum, daha çeşitli ve yüksek kaliteli veri toplanarak veya özellikle bu sınıfa yönelik veri artırma (augmentation) stratejileri uygulanarak iyileştirilebilir.

Bir diğer eksik nokta, modelin yalnızca beş sınıfla sınırlı olmasıdır. Gerçek dünya senaryolarında farklı gemi tiplerinin, örneğin balıkçı teknelerinin veya petrol tankerlerinin de tanınması gerekebilir. Veri setine yeni sınıflar eklenerek model genişletilebilir ve sistemin kapsayıcılığı artırılabilir.

Ek olarak, sistem şu anda yalnızca yüklenen görüntüler üzerinden çalışmaktadır. Gerçek zamanlı video akışı desteği veya dronlardan/sensörlerden gelen canlı görüntülerin işlenmesi, projenin sahadaki etkinliğini ve kullanım alanını önemli ölçüde genişletebilir.

## 5. Sonuç

Bu çalışmada, yapay zeka destekli bir gemi sınıflandırma ve uyarı sistemi başarıyla geliştirilmiştir. Projede geliştirilen derin öğrenme modeli, kullanıcıların mobil cihazları aracılığıyla yüklediği gemi görüntülerini analiz ederek gemi türünü belirlemekte ve özellikle tehlikeli durumlar olan “savaş gemisi” tespiti hâlinde anlık bildirim yoluyla yetkilileri uyarmaktadır. Bu süreçte modelin kararlarına ek olarak, kullanıcının bulunduğu konum da Google Maps entegrasyonu ile harita üzerinde işaretlenmekte ve ilgili bilgiler Firebase Firestore üzerinde kayıt altına alınmaktadır.

Eğitim, doğrulama ve test verileri üzerinde yapılan değerlendirmeler sonucunda modelin test doğruluğu %91.78 olarak ölçülmüş; sınıflandırma başarımı tüm sınıflarda dengeli ve yüksektir. Özellikle “sailboat” ve “warship” sınıflarında yüksek doğruluk ve F1 skorları elde edilmiştir. Karışıklık matrisi ve sınıflandırma raporları, modelin pratikte kullanılabilir bir düzeye ulaştığını ortaya koymaktadır.

Proje kapsamında sadece yüksek doğrulukta bir yapay zeka modeli geliştirilmemiş; aynı zamanda bu modelin gerçek zamanlı kullanımına olanak sağlayan bir mobil uygulama, harita tabanlı takip sistemi ve uyarı altyapısı da entegre edilmiştir. Bu yönüyle çalışma, klasik sınıflandırma projelerinden farklı olarak sahada kullanılabilir, güvenlik odaklı ve kullanıcı dostu bir çözüm sunmaktadır.

Sonuç olarak bu proje, deniz güvenliğine katkı sağlayacak yenilikçi bir yaklaşım sunmakta ve yapay zekanın mobil ortamlarda nasıl etkili bir şekilde kullanılabileceğine dair başarılı bir örnek teşkil etmektedir.

## KAYNAKÇA

- [1] Tiwari, B. K., Munagala, R. S., & Mannarugudi, S. D. (2024, October). CNN Models Transfer Learning Based Ship Classification for Intelligent Ship Routing. In *2024 IEEE International Conference on Computer Vision and Machine Intelligence (CVMI)* (pp. 1-6). IEEE.
- [2] Stofa, M. M., Zulkifley, M. A., & Zaki, S. Z. M. (2020, July). A deep learning approach to ship detection using satellite imagery. In *IOP Conference Series: Earth and Environmental Science* (Vol. 540, No. 1, p. 012049). IOP Publishing.
- [3] Zhang, D., Liu, J., Heng, W., Ren, K., & Song, J. (2018, March). Transfer learning with convolutional neural networks for SAR ship recognition. In *IOP Conference Series: Materials Science and Engineering* (Vol. 322, p. 072001). IOP Publishing.
- [4] Xia, G. S., Bai, X., Ding, J., Zhu, Z., Belongie, S., Luo, J., ... & Zhang, L. (2018). DOTA: A large-scale dataset for object detection in aerial images. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 3974-3983).

[5] Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., ... & Zheng, X. (2016). {TensorFlow}: a system for {Large-Scale} machine learning. In *12th USENIX symposium on operating systems design and implementation (OSDI 16)* (pp. 265-283).